

Análise Estrutural e Algorítmica do Grafo do SNAP: 96 million memes from Memetracker

Rafael Silva Santana
Universidade Federal da Bahia
Salvador, Brasil
rsntn@ufba.br

RESUMO

Este relatório apresenta uma investigação estrutural de um grafo de citações em larga escala (dataset *Memetracker*), contendo quase 700 mil nós. Através de três etapas de experimentação, o trabalho mapeia a anatomia da propagação de informações na Web. A primeira etapa foca na extração das métricas fundamentais e na caracterização esparsa da Maior Componente Conexa (LCC). A segunda etapa promove uma análise empírica de algoritmos clássicos, atestando matematicamente o *overhead* de buscas otimizadas para caminhos de custo mínimo (Dijkstra) perante abordagens lineares (BFS) em redes não-ponderadas. Por fim, a terceira etapa comprova que o fluxo de memes adere ao modelo de Ligação Preferencial (Barabási-Albert), exibindo propriedades indissociáveis de Mundo Pequeno e rede Livre de Escala. Os ensaios de robustez demonstram o paradoxo dessa topologia: uma resistência impenetrável a falhas randômicas, ofuscada por uma fragilidade sistêmica severa sob ataques direcionados a menos de 5% de seus *hubs*.

PALAVRAS-CHAVE

Teoria dos Grafos, Redes Complexas, Algoritmos, Análise Estrutural

1 INTRODUÇÃO

O estudo empírico de Redes Complexas tornou-se uma das ferramentas mais poderosas para a compreensão de ecossistemas dinâmicos. Redes do mundo real, como interações ecológicas, rotas metabólicas e redes sociais, frequentemente rejeitam a aleatoriedade pura (modelo Erdős-Rényi), auto-organizando-se em arquiteturas assimétricas repletas de atalhos globais.

Neste cenário, o presente trabalho se propõe a mapear a topologia do *Memetracker*, um massivo grafo de difusão de hiperlinks e citações coletado pelo *Stanford Network Analysis Project* (SNAP) [3]. A seleção deste dataset justifica-se por ele representar um autêntico laboratório orgânico de disseminação comunicacional: a jornada fractal e explosiva de tendências midiáticas por mais de um milhão de arestas na internet de 2008.

Para extrair os mecanismos internos dessa teia colossal, fragmentamos nossa metodologia em três escopos. A etapa inicial foca na varredura estrutural estática, expondo a conectividade macroscópica da rede através de seu Diâmetro e Coeficientes de Clusterização. No escopo algorítmico intermediário, desafiamos teorias de complexidade confrontando cronômetros de execução real de algoritmos fundacionais (Buscas, Árvores Geradoras e Caminhos Mínimos). Em sua culminância analítica, o trabalho testa a aderência topológica aos fenômenos de Lei de Potência e *Small-World*, encerrando com simulações computacionais de estresse que revelam o verdadeiro calcanhar de Aquiles das infraestruturas de informação global.

2 DESCRIÇÃO DO GRAFO E TRATAMENTO DE DADOS

O grafo a ser analisado foi determinado através de uma função de mapeamento baseada na matrícula do discente ($M = 223216616$). A regra estipulada, definida por $f(M) = ((\text{soma dos dígitos de } M) \times (\text{últimos 2 dígitos de } M + 1)) \pmod{129}$, resultou no seguinte cálculo: $f(M) = (29 \times 17) \pmod{129} = 493 \pmod{129} = 106$. O índice 106 atribuiu formalmente a este trabalho o *dataset* do *Memetracker* (agosto de 2008), fornecido pelo *Stanford Network Analysis Project* (SNAP).

O grafo original do *Memetracker* representa uma rede de citações intrinsecamente direcionada (um site aponta para outro) e multiaresta (várias citações entre os mesmos sites no mesmo dia). Utilizamos uma amostra correspondente aos dias 01 e 02 de Agosto de 2008 devido ao elevado volume de dados brutos (4.1GB originais). Para viabilizar a análise geral em memória, optamos pela máxima transparência, realizando as seguintes adaptações teóricas no grafo original:

- **Filtragem Temporal:** Redução da amostra para os dias 01 e 02 de Agosto para viabilizar o processamento em memória.
- **Grafo Estático:** Conversão do grafo temporal em estático através da união de todas as arestas ao longo do tempo analisado.
- **Conversão para Grafo Simples:** O multigrafo original possuía arestas duplicadas (múltiplas citações), que foram colapsadas em conexões únicas.
- **Conversão de Dirigido para Não-Direcionado:** A remoção das direções das arestas evitou caminhos bloqueados por nós sumidouros, permitindo o mapeamento de todo o tecido conectivo estrutural.
- **Remoção de Auto-loops:** Citações de um domínio para ele mesmo foram expurgadas, pois não afetam a conectividade externa.
- **Extração da Maior Componente Conexa (LCC):** Devido à fragmentação e existência de milhares de componentes isoladas menores, extraiu-se exclusivamente a LCC para os ensaios de Diâmetro, Caminhos Mínimos e Robustez.
- **Conversão para Lista de Adjacência:** Estruturamos o grafo na memória utilizando Listas de Adjacência. A representação via Matriz de Adjacência para quase 700 mil nós exigiria centenas de Gigabytes de RAM, provando-se inútil e inviável para redes ralas e massivas.

3 METODOLOGIA

Todo o pipeline de engenharia de dados, cálculos estruturais e prototipagem algorítmica foi conduzido utilizando a linguagem Python 3. A modelagem matemática do grafo foi arquitetada sobre

a biblioteca NetworkX, que garantiu as abstrações necessárias para o cômputo da Maior Componente Conexa (LCC) e extração veloz de métricas de centralidade.

Para os cálculos estatísticos inferenciais, a aproximação do Mundo Pequeno via modelo Erdős-Rényi e a extração da Reta de Regressão da Lei de Potência, utilizou-se a integração das bibliotecas SciPy e NumPy. A vetorização dos *logs* de tempo das milhares de chamadas aos algoritmos de busca, bem como o tratamento das séries estatísticas e Intervalos de Confiança, foram orquestrados com a biblioteca Pandas.

Adicionalmente, métodos de amostragem estocástica foram implementados para conduzir as simulações probabilísticas de ataque e resiliência topológica. A renderização gráfica das Ego-Networks, dispersões em Log-Log e *Boxplots* das simulações de colapso foram programadas via Matplotlib. O ambiente de prototipagem adotado foi o Jupyter Notebook, visando isolar experimentos pesados e garantir a reprodutibilidade metodológica passo-a-passo.

A totalidade do código-fonte, o pipeline algorítmico, o dataset pré-processado e o manual de replicação *open-source* (README) encontram-se hospedados e versionados publicamente no repositório: <https://github.com/rafass03/rafael-santana-memetracker>.

4 ANÁLISE ESTRUTURAL DO GRAFO

Nesta etapa, extraímos as métricas fundamentais para compreender a escala da rede de comunicação. Todas as medidas exigidas foram computadas com sucesso. A Tabela 1 e as Figuras 1 e 2 resumem os valores encontrados. Para o Diâmetro, Raio e Comprimento Médio dos caminhos, adotou-se amostragem de 500 vértices na Maior Componente Conexa (LCC) devido à inviabilidade computacional de rodar algoritmos exatos em tempo razoável para 321.645 vértices.

Tabela 1: Métricas Estruturais do Grafo (Estático S/ Auto-Loops)

Métrica	Valor
Número de vértices	687.347
Número de arestas	1.166.699
Grau (Mín/Máx/Médio)	0 / 3.600 / 3,3948
Densidade	0,000005
Distribuição de Graus	Ver Figura 1
Número de Componentes	45.925
Tamanho de Cada Componente	A maior tem 321.645 vértices*
Vértices (Maior Componente)	321.645 (46,80%)
Arestas (Maior Componente)	596.233 (51,10%)
Diâmetro	48
Raio	28
Compr. Médio Caminhos	13,5707
Coef. Clusterização	0,0441
Número de Triângulos	1.576.302

*As demais variam entre 2 e 50 vértices.

Analisando os dados da Tabela 1, a rede revela uma topologia extremamente esparsa, evidenciada por sua densidade quase nula (0,000005) e um grau médio de apenas $\approx 3,39$ conexões por blog. No entanto, a disparidade de ligações é abissal: enquanto a vasta

maioria dos nós possui conexões marginais, o vértice mais popular ostenta um grau máximo de 3.600, atestando a presença de super-*hubs* concentradores de atenção. Embora o grafo se encontre fragmentado em 45.925 componentes isoladas, quase todo o fluxo informacional é canalizado por uma única superestrutura macroscópica: a Maior Componente Conexa (LCC). Funcionando como a "espinha dorsal" da propagação de memes, a LCC abriga sozinha quase metade dos sites (46,80%) e engole 51,10% de todas as arestas do ecossistema. Além disso, o impressionante número de triângulos na rede (1.576.302) e seu coeficiente de clusterização (0,0441) sugerem uma fortíssima tendência humana à formação de comunidades e "bolhas sociais" locais altamente entrelaçadas.




Figura 1: Distribuição de Graus em escala Log-Log.




Figura 2: Visualização de Ego-Network retirada da Maior Componente Conexa (amostra com 801 nós).

Esta topologia excêntrica pode ser visualmente confirmada por meio das Figuras 1 e 2. Na Figura 1, a plotagem da distribuição de graus em escala *log-log* revela uma reta descendente nítida, o que comprova matematicamente que a rede do *Memetracker* obedece a uma rígida Lei de Potência (*Power-Law*). É este comportamento que tipifica o ecossistema como uma rede *Scale-Free* (Livres de Escala). Já a Figura 2 materializa essa teoria em um panorama geométrico tridimensional: ao observar a amostra da ego-network, nota-se o núcleo central estritamente coeso e monopolista de *hubs* (os gigantes da

mídia). Devido à imensa relevância estrutural da Maior Componente Conexa (LCC) e visando garantir a viabilidade computacional de desempenho das execuções, as seções subsequentes realizarão todas as simulações e buscas de caminhos exclusivamente nela.

5 DESEMPENHO E COMPLEXIDADE DOS ALGORITMOS

Nesta seção, implementamos algoritmos clássicos para avaliar o tempo de execução e comparar com a complexidade teórica. O rigor estatístico incluiu Intervalos de Confiança (IC 95%).

Analisando os resultados da Tabela 2, a travessia completa da LCC evidenciou que a DFS foi mais do que o dobro mais rápida que a BFS ($\bar{x} = 0,94s$ contra $\bar{x} = 2,37s$). Embora possuam a mesma complexidade teórica $O(V + E)$, a natureza de pilha do DFS demonstra maior eficiência prática em redes *Scale-Free*. O BFS, por sua vez, sofre um gargalo de tempo e memória ao precisar armazenar muitos vértices (fila de prioridade) de uma só vez nos níveis intermediários da busca, em decorrência do altíssimo grau dos *hubs* da rede.

O algoritmo de Tarjan, por sua vez, registrou $\bar{x} = 6,42s$ na identificação de Componentes Fortemente Conexas (SCC). Diferente das métricas anteriores que operaram no modelo não-direcionado, o Tarjan obrigatoriamente atuou sobre a versão direcionada do grafo, visto que o conceito de conectividade forte depende do fluxo de mão única das arestas. A necessidade de rastrear índices de descobrimento e valores de *low-link* para cada nó elevou substancialmente a constante de tempo da operação, tornando-o o algoritmo $O(V + E)$ mais lento da bateria de testes.

Ainda sobre a Tabela 2, fica evidente a explosão combinatória $O(V^3)$ do Floyd-Warshall, que levou 1,73 segundos para ínfimos 200 nós. Ademais, para um grafo desprovido de pesos, o uso de caminhos mínimos ponderados (Dijkstra e Bellman-Ford) provou-se matematicamente redundante. O BFS, em testes de 30 rodadas com exatos 5.000 nós, concluiu a busca de menor caminho $\approx 3\times$ mais rápido que o Dijkstra ($\bar{x} = 0,00856s$ vs $\bar{x} = 0,02622s$), comprovando empiricamente que a fila de prioridade apenas introduz um gargalo de tempo em grafos onde todas as arestas custam 1.

Da mesma forma, o Bellman-Ford foi o mais lento dessa amostra de 5.000 nós ($\bar{x} = 0,03635s$), pois seu propósito é lidar com arestas de pesos negativos, forçando relaxamentos excessivos de $O(V \times E)$ que são completamente desnecessários em um grafo não ponderado. O mesmo ocorreu para Árvores Geradoras Mínimas: como toda árvore geradora possui peso $V - 1$, a otimização inerente ao Prim/Kruskal é inócua aqui.

Por fim, nota-se que a Verificação Euleriana executou em tempo virtualmente nulo (0,00000s). Isso ocorre pois grafos de lei de potência possuem milhares de nós com grau 1 (ímpar). Pelo Teorema de Euler, basta um vértice de grau ímpar para violar a condição. Assim, o algoritmo aborta instantaneamente por avaliação de curto-circuito logo na primeira checagem.

6 PROPRIEDADES AVANÇADAS E ROBUSTEZ

Para investigar as propriedades estruturais profundas e a resiliência desta rede em larga escala, fez-se necessário o emprego de métodos estocásticos e aproximações computacionais, dada a inviabilidade temporal de realizar cálculos combinatórios exatos em uma LCC

de 321.645 vértices. Consequentemente, simulações avançadas produzem métricas com ínfimas flutuações decimais entre diferentes execuções. Essa estocasticidade é um fenômeno metodologicamente esperado na Ciência de Redes Complexas e Métodos Numéricos, preservando intactas as ordens de grandeza e as validações matemáticas do grafo.

Nas subseções a seguir, aplicamos este rigor analítico para des-trinchar três características fundamentais da rede: o fenômeno estrutural de Mundo Pequeno (*Small-World*), o ajuste geométrico à Lei de Potência, e a Robustez topológica sistêmica perante perdas caóticas e ataques direcionados predatórios.

6.1 Mundo Pequeno (Small-World)

Para responder se a LCC apresenta a propriedade de *Small-World*, verificou-se se $C(G) \gg C_{rand}$ e $L(G) \approx L_{rand}$. No grafo real obtivemos $C \approx 0,0435$ e $L \approx 13,51$. Para um Erdős-Rényi equivalente, os cálculos indicaram $C_{rand} \approx 0,000012$ e $L_{rand} \approx 9,67$. Ao aplicarmos o coeficiente de *small-worldness* de Humphries e Gurney, obtivemos $\sigma \approx 2703,09 \gg 1$.

Isso prova que faz sentido o grafo ser *Small-World* e implica, na prática, a profundidade do *Memetracker*. A informação e as tendências navegam entre dois blogs quaisquer quase instantaneamente se ancorando em pouquíssimos atalhos intermediários, mesmo em uma rede com forte viés de bolhas sociais locais.

6.2 Lei de Potência

Como comentando no tópico 4, a distribuição de graus sugere uma Lei de Potência. Analisando a dispersão na Figura 3, a regressão linear apontou uma reta de forte aderência com decaimento $\gamma \approx 1,70$ (e um $R^2 \approx 0,78$), obedecendo à assinatura clássica $P(k) \sim k^{-\gamma}$. Isso classifica de forma inequívoca a nossa rede como "Livre de Escala" (*Scale-Free*), com a quase totalidade dos domínios sendo marginais e uma fração minúscula de sites operando como supercentros gravitacionais (*hubs*).




Figura 3: Dispersão Log-Log e a Reta de Regressão da Lei de Potência.

6.3 Robustez do Grafo

Testamos a resiliência da rede submetendo-a à perda brusca de 5% dos nós (16.082 vértices). Sob Remoção Aleatória em $T = 30$ rodadas (Figura 4), o grafo foi impenetrável: a LCC sobreviveu restando

Tabela 2: Desempenho e Estatística dos Algoritmos na LCC e Subgrafos

Algoritmo	Complexidade Teórica	Média ($\bar{x}$)	Desv. Padrão (σ)	IC (95%)	Dist. (n)
Busca em Largura (BFS)	$O(V + E)$	2,37948s	0,50197s	[2,1999s, 2,5591s]	Normal (30)
Busca em Prof. (DFS)	$O(V + E)$	0,94733s	0,21027s	[0,8721s, 1,0226s]	Normal (30)
Algoritmo de Tarjan (SCC)*	$O(V + E)$	6,42630s	0,68411s	[6,1815s, 6,6711s]	Normal (30)
Verificação Euleriana	$O(V)$	0,00000s	0,00000s	[0,0000s, 0,0000s]	Normal (30)
Prim	$O(E \log V)$	8,45776s	0,66810s	[8,2187s, 8,6968s]	Normal (30)
Kruskal	$O(E \log E)$	8,74120s	0,74381s	[8,4750s, 9,0074s]	Normal (30)
BFS (Caminho Mínimo)**	$O(V + E)$	0,00856s	0,00138s	[0,0081s, 0,0091s]	Normal (30)
Dijkstra**	$O((V + E) \log V)$	0,02622s	0,00195s	[0,0255s, 0,0269s]	Normal (30)
Bellman-Ford**	$O(V \times E)$	0,03635s	0,00200s	[0,0356s, 0,0371s]	Normal (30)
Floyd-Warshall***	$O(V^3)$	1,73234s	0,05612s	[1,6922s, 1,7725s]	t-Student (10)

*O Tarjan foi executado na versão direcionada.

**Para viabilidade técnica, executados em subgrafo conectado de 5.000 vértices.

***Devido à explosão combinatória $O(V^3)$, o Floyd-Warshall executou em apenas 200 vértices.

em média 281.518 nós íntegros e amargando meros 3,92% de nós isolados. Porém, perante um Ataque Direcionado apagando apenas os 5% top *hubs* (pela métrica de Centralidade de Grau), a estrutura virou poeira: a grande LCC despedaçou-se em 239.507 subcomponentes isoladas, restando apenas 2.325 vértices conectados. Cerca de 76,36% do grafo ficou absolutamente desconectado e isolado do mundo. A rede é robusta ao caos, mas refém de sua elite central.

tecido robusto por um lado, mas introduz um ponto crítico de falha global.

6.5 Modelos Clássicos

As evidências estatísticas comprovam que a rede analisada espelha quase com perfeição o Modelo Clássico de Barabási-Albert (BA). Toda a assimetria matemática de vulnerabilidade se deve ao mecanismo basal desse modelo: a Ligação Preferencial (*Preferential Attachment*). Na difusão de mídias, sites emergentes apontam hiperlinks para portais globais já consolidados. Essa evolução explica simultaneamente a formação da *Power Law*, o atalho magnético do *Small-World* e o colapso catastrófico perante o ataque direcionado aos *hubs*.

7 DISCUSSÃO CRÍTICA

Analisando o relatório em uma perspectiva holística, percebe-se que os três processos deste projeto convergem para uma única narrativa coesa sobre redes da vida real. A análise estrutural revelou uma rede de proporções massivas (quase 700 mil nós) mas de baixíssima densidade, provando que a internet é escassamente e seletivamente conectada em sua raiz. O desempenho evidenciou empiricamente que algoritmos acadêmicos complexos baseados em otimização de custos (como Dijkstra) tornam-se inócuos e contraproducentes em teias sociais orgânicas não-ponderadas, cenário no qual algoritmos diretos como a BFS dominam em performance. Finalmente, a última seção costurou essas características para extrair o comportamento macro do grafo: o "Mundo Pequeno Livre de Escalas". A rede do Memetracker não é apenas um emaranhado aleatório, mas sim um ecossistema auto-organizado pela riqueza de cliques (*hubs*), cujo distanciamento curto facilita enormemente a viralização de memes, mas sacrifica a descentralização do sistema.

A intersecção destas propriedades matemáticas arquitetou o paradoxo de resiliência mais expressivo deste relatório: enquanto falhas randômicas massivas falham em destruir a conectividade global, um ataque cirúrgico aos 5% *hubs* centrais provoca o colapso e o isolamento de 76% de todo o ecossistema analisado. Essa dualidade entre "Mundo Pequeno" e "Lei de Potência" força a engenharia de




Figura 4: Boxplots das falhas aleatórias vs colapso pontual pelo ataque (estrela vermelha).

6.4 Descoberta Interessante do Grafo

A descoberta empírica mais impressionante do grafo é a discrepância da resiliência estrutural. A rede exibe uma incrível dualidade: ao mesmo tempo em que a gigantesca LCC suporta ataques perfeitamente se a falha for estocástica, ela sofre pane quase total ao perdermos apenas as dezenas de sites da "elite". Isso demonstra uma fraqueza na topologia de comunicação da internet, que constrói um

software a repensar a tolerância a falhas na Web, evidenciando como vulnerabilidades críticas emergem organicamente em sistemas de Ligação Preferencial. Como principal limitação deste estudo, reconhecemos que a conversão obrigatória do grafo para um modelo estático ocultou a dinâmica cronológica de formação das anomalias de centralidade, impedindo rastrear o exato momento em que um nó comum se torna um super *hub*.

8 CONCLUSÃO

A investigação estrutural e algorítmica conduzida sobre o dataset do *Memetracker* atendeu com êxito a todos os objetivos propostos. Através da extração de métricas de centralidade, validação cronométrica de algoritmos e modelagem estatística rigorosa, o trabalho mapeou integralmente o funcionamento interno da propagação viral na era digital.

Concluimos formalmente que a difusão de informações na internet rejeita a aleatoriedade e opera sob estruturas estritamente hierárquicas e assimétricas. A rede é regida por uma pequena elite hiper-conectada, o que garante velocidades astronômicas na viralização de tendências (encurtando distâncias para uma média de 13 cliques), mas herda, por consequência, uma vulnerabilidade estrutural catastrófica a ataques focados. Em suma, o projeto demonstrou empiricamente como leis abstratas da teoria dos grafos governam redes reais, provendo um diagnóstico cristalino e ferramentas metodológicas sólidas na análise de grandes volumes de dados.

REFERÊNCIAS

- [1] Contribuidores da Wikipédia. 2026. Centralidade — Wikipédia, A enciclopédia livre. <https://pt.wikipedia.org/wiki/Centralidade> [Online; acessado em 17-junho-2026].
- [2] Contribuidores da Wikipédia. 2026. Redes de pequeno mundo — Wikipédia, A enciclopédia livre. https://pt.wikipedia.org/wiki/Redes_de_pequeno_mundo [Online; acessado em 17-junho-2026].
- [3] Stanford Network Analysis Project (SNAP). 2009. 96 million memes from Memetracker. <https://snap.stanford.edu/data/memetracker9.html> [Online; acessado em 17-junho-2026].
- [4] Wikipedia contributors. 2026. Centrality — Wikipedia, The Free Encyclopedia. <https://en.wikipedia.org/wiki/Centrality> [Online; acessado em 17-junho-2026].
- [5] Wikipedia contributors. 2026. Power law — Wikipedia, The Free Encyclopedia. https://en.wikipedia.org/wiki/Power_law [Online; acessado em 17-junho-2026].
- [6] Wikipedia contributors. 2026. Small-world network — Wikipedia, The Free Encyclopedia. https://en.wikipedia.org/wiki/Small-world_network [Online; acessado em 17-junho-2026].